

5.6 条件分布与条件期望

前面学过随机事件的条件概率, 即在事件 B 发生的条件下事件 A 发生的条件概率

$$P(A|B) = P(AB)/P(B).$$

相关概念可推广到随机变量: 在给定随机变量 Y 取值条件下, 求 X 的概率分布, 即条件分布.

首先考虑离散型随机变量:

定义5.12. 设 (X, Y) 为二维离散型随机变量, 其分布列为 $\{p_{ij}\}$. 若 Y 的边缘分布 $P(Y = y_j) = p_{\cdot j} > 0$, 称

$$P(X = x_i | Y = y_j) = \frac{P(X = x_i, Y = y_j)}{P(Y = y_j)} = \frac{p_{ij}}{p_{\cdot j}}, \quad i = 1, 2, \dots$$

为在 $Y = y_j$ 条件下随机变量 X 的条件分布列.

类似可定义在 $X = x_i$ 条件下随机变量 Y 的条件分布列. 条件分布是一种概率分布, 具有分布的一切性质, 例如:

- 非负性: $P(X = x_i | Y = y_j) \geq 0$;
- 规范性: $\sum_{i=1}^{\infty} P(X = x_i | Y = y_j) = 1$.

例5.14. 一射手进行射击, 击中目标的概率为 p , 射击进行到击中两次目标为止. X 表示首次击中目标所进行的射击次数, Y 表示第二次击中目标所进行的射击次数, 求 X 和 Y 的联合分布和条件分布.

解. 随机变量 $X = m$ 表示首次击中目标射击了 m 次, $Y = n$ 表示第二次击中目标射击了 n 次, 则 X 和 Y 的联合分布列为:

$$P\{X = m, Y = n\} = p^2(1-p)^{n-2} \quad 1 \leq m < n < \infty.$$

由此可得 X 的边缘分布列为

$$P\{X = m\} = \sum_{n=m+1}^{\infty} P\{X = m, Y = n\} = \sum_{n=m+1}^{\infty} p^2(1-p)^{n-2} = p^2 \frac{(1-p)^{m-1}}{1-(1-p)} = p(1-p)^{m-1}.$$

同理得到随机变量 Y 的边缘分布列为

$$P\{Y = n\} = \sum_{m=1}^{n-1} P\{X = m, Y = n\} = \sum_{m=1}^{n-1} p^2(1-p)^{n-2} = (n-1)p^2(1-p)^{n-2} \quad (n = 2, 3, \dots).$$

因此, 当 $n = 2, 3, \dots$ 时, 随机变量 X 在 $Y = n$ 条件下的分布列为:

$$P\{X = m | Y = n\} = \frac{P\{X = m, Y = n\}}{P\{Y = n\}} = \frac{p^2(1-p)^{n-2}}{(n-1)p^2(1-p)^{n-2}} = \frac{1}{n-1} \quad m = 1, 2, \dots, n-1.$$

当 $m = 1, 2, 3, \dots$ 时, 随机变量 Y 在 $X = m$ 条件下的分布列为:

$$P\{Y = n | X = m\} = \frac{P\{X = m, Y = n\}}{P\{X = m\}} = \frac{p^2(1-p)^{n-2}}{p(1-p)^{m-1}} = p(1-p)^{n-m-1} \quad n = m+1, m+2, \dots$$

□

对于连续型随机变量 (X, Y) , 对任意 x, y , 有 $P(X = x) = 0$ 和 $P(Y = y) = 0$ 成立, 因此不能利用条件概率得到条件分布. 下面给出条件概率的定义:

定义5.13. 设连续型 X 和 Y 的联合概率密度为 $f(x, y)$, 随机变量 Y 的边缘概率密度为 $f_Y(y)$, 对任意 y , $f_Y(y) > 0$, 称

$$f_{X|Y}(x|y) = \frac{f(x, y)}{f_Y(y)}$$

在 $Y = y$ 条件下随机变量 X 的条件概率密度. 称

$$F_{X|Y}(x|y) = P\{X \leq x | Y = y\} = \int_{-\infty}^x f_{X|Y}(u|y) du$$

为 $Y = y$ 条件下 X 的条件分布函数.

类似定义在 $X = x$ 条件下随机变量 Y 的条件概率密度和分布函数分别为

$$f_{Y|X}(y|x) = \frac{f(x, y)}{f_X(x)} \quad F_{Y|X}(y|x) = \int_{-\infty}^y \frac{f(x, v)}{f_X(x)} dv.$$

下面解释条件概率的含义, 这里以 $f_{X|Y} = \frac{f(x, y)}{f_Y(y)}$ 为例, 首先分布函数有

$$F_{X|Y}(x|y) = P\{X \leq x | Y = y\} = \lim_{\epsilon \rightarrow 0^+} P\{X \leq x | y \leq Y \leq y + \epsilon\} = \lim_{\epsilon \rightarrow 0^+} \frac{P\{X \leq x, y \leq Y \leq y + \epsilon\}}{P\{y \leq Y \leq y + \epsilon\}}.$$

根据积分中值定理有

$$\frac{P\{X \leq x, y \leq Y \leq y + \epsilon\}}{P\{y \leq Y \leq y + \epsilon\}} = \frac{\int_{-\infty}^x \int_y^{y+\epsilon} f(u, v) du dv}{\int_y^{y+\epsilon} f_Y(u) dv} = \frac{\epsilon \int_{-\infty}^x f(u, y + \theta_1 \epsilon) du}{\epsilon f_Y(y + \theta_2 \epsilon)}$$

其中 $\theta_1, \theta_2 \in (0, 1)$. 当 $\epsilon \rightarrow 0^+$ 时, 有

$$F_{X|Y}(x|y) = P\{X \leq x | Y = y\} = \lim_{\epsilon \rightarrow 0^+} P\{X \leq x | y \leq Y \leq y + \epsilon\} = \frac{\int_{-\infty}^x f(u, y) du}{f_Y(y)} = \int_{-\infty}^x \frac{f(u, y)}{f_Y(y)} du,$$

由此可得条件概率密度 $f_{X|Y}(x|y) = f(x, y)/f_Y(y)$. 下面给出条件概率的性质:

引理5.2 (乘法公式). 对于随机变量 X 和 Y , 有

$$\begin{aligned} f(x, y) &= f_X(x) f_{Y|X}(y|x), \quad (f_X(x) > 0), \\ f(x, y) &= f_Y(y) f_{X|Y}(x|y), \quad (f_Y(y) > 0). \end{aligned}$$

引理5.3. 如果随机变量 X 和 Y 相互独立, 则有

$$f_{Y|X}(y|x) = f_Y(y) \quad f_{X|Y}(x|y) = f_X(x).$$

由条件概率可判别随机变量 (X, Y) 是否独立. 下面看几个例子:

例5.15. 设 (X, Y) 的概率密度

$$f(x, y) = \begin{cases} \frac{e^{-x/y} e^{-y}}{y} & 0 < x < +\infty, 0 < y < +\infty \\ 0 & \text{其它} \end{cases}$$

求 $P(X > 1|Y = y)$.

解. 首先求解随机变量 Y 的边缘分布为

$$f_Y(y) = \int_0^{+\infty} \frac{e^{-x/y} e^{-y}}{y} dx = e^{-y} [-e^{-\frac{x}{y}}]_0^{+\infty} = e^{-y} \quad (y > 0).$$

进而得到在 $Y = y$ 条件下 X 的条件概率密度为 $f_{X|Y}(x|y) = e^{-x/y}/y$. 最后得到

$$P(X > 1|Y = y) = \int_1^{\infty} \frac{e^{-x/y}}{y} dx = -e^{-x/y}|_1^{\infty} = e^{-\frac{1}{y}}.$$

□

例5.16. 设 $X \sim U(0, 1)$, 当观察到 $X = x$ 的条件下, 随机变量 $Y \sim U(x, 1)$. 求 Y 的概率密度.

解. 根据题意可知 $X \sim U(0, 1)$, 在随机变量 $X = x$ 的条件下 $Y \sim U(x, 1)$, 即 $f_{Y|X}(y|x) = \frac{1}{1-x}$. 根据条件概率乘积公式有

$$f(x, y) = f_X(x) f_{Y|X}(y|x) = \begin{cases} \frac{1}{1-x} & 0 < x < y < 1, \\ 0 & \text{其它}. \end{cases}$$

根据联合分布求解随机变量 X 的边缘分布

$$f_Y(y) = \int_{-\infty}^{+\infty} f(x, y) dx = \begin{cases} \int_0^y \frac{1}{1-x} dx = -\ln(1-y) & y > 0, \\ 0 & \text{其它}. \end{cases}$$

□

习题. 设 (X, Y) 的概率密度为

$$f(x, y) = \begin{cases} e^{-y} & y > x > 0 \\ 0 & \text{其它} \end{cases}$$

求 $f_{X|Y}(x|y)$.

定理5.17. 多维正太分布的条件分布是正太分布.

Proof. 为简单起见, 这里仅仅给出二维正太分布的详细证明. 设 $X = (X_1, X_2) \sim \mathcal{N}(\mu, \Sigma)$, $\mu = (\mu_1, \mu_2)$, $\Sigma = \begin{pmatrix} \sigma_1^2 & \rho\sigma_1\sigma_2 \\ \rho\sigma_1\sigma_2 & \sigma_2^2 \end{pmatrix}$, 在 $X_2 = x_2$ 的条件下证明 $X_1 \sim \mathcal{N}(\mu_1 - \sigma_1^2\rho(x_2 - \mu_2)/\sigma_2^2, \sigma_1^2(1 - \rho^2))$. 首先给出二维正太分布的联合分布

$$f(x_1, x_2) = \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} e^{-\frac{1}{2} \frac{1}{(1-\rho)^2} [\frac{(x_1-\mu_1)^2}{\sigma_1^2} - 2\rho \frac{(x_1-\mu_1)(x_2-\mu_2)}{\sigma_1\sigma_2} + \frac{(x_2-\mu_2)^2}{\sigma_2^2}] }.$$

以及随机变量 X_2 的边缘分布为 $X_2 \sim \mathcal{N}(\mu_2, \sigma_2^2)$. 于是得到条件概率

$$\begin{aligned} f_{X_1|X_2}(x_1|x_2) &= \frac{1}{\sqrt{2\pi}\sigma_1\sqrt{1-\rho^2}} e^{-\frac{1}{2}\frac{1}{(1-\rho)^2}\left[\frac{(x_1-\mu_1)^2}{\sigma_1^2}-2\rho\frac{(x_1-\mu_1)(x_2-\mu_2)}{\sigma_1\sigma_2}+\rho^2\frac{(x_2-\mu_2)^2}{\sigma_2^2}\right]} \\ &= \frac{1}{\sqrt{2\pi}\sigma_1\sqrt{1-\rho^2}} e^{-\frac{1}{2}\frac{1}{(1-\rho)^2}\left[\frac{x_1-\mu_1}{\sigma_1}+\frac{\rho(x_2-\mu_2)}{\sigma_2}\right]^2} \\ &= \frac{1}{\sqrt{2\pi}\sigma_1\sqrt{1-\rho^2}} e^{-\frac{1}{2}\frac{1}{\sigma_1^2(1-\rho)^2}[x_1-\mu_1+\sigma_1^2\rho^2(x_2-\mu_2)/\sigma_2^2]^2}. \end{aligned}$$

因此在 $X_2 = x_2$ 条件下, $X_1 \sim \mathcal{N}(\mu_1 - \sigma_1^2\rho(x_2 - \mu_2)/\sigma_2^2, \sigma_1^2(1 - \rho^2))$. □

5.6.1 条件期望

定义5.14. 若 X, Y 为离散型随机变量,

$$E[X|Y = y] = \sum_{i=1}^{\infty} x_i P(X = x_i|Y = y).$$

若 X, Y 为连续型随机变量,

$$E[X|Y = y] = \int_{-\infty}^{+\infty} x f(x|y) dx.$$

注: $E[X|Y = y]$ 是 y 的函数. 对条件期望, 有如下重要性质:

定理5.18. 对离散随机变量 X_1, X_2, \dots, X_n 及常数 c_1, c_2, \dots, c_n , 有

$$E\left[\sum_{i=1}^n c_i X_i | Y = y\right] = \sum_{i=1}^n c_i E[X_i | Y = y].$$

定理5.19 (全期望公式, law of total expectation). 对随机变量 X 和事件 A 有

$$E[X] = E[X|A]P(A) + E[X|\bar{A}](1 - P(A))$$

其中事件 \bar{A} 为事件 A 的补.

Proof. 利用全概率公式有

$$\begin{aligned} E[X] &= \sum_i x_i P(X = x_i) = \sum_i x_i [P(X = x_i, A) + P(X = x_i, \bar{A})] \\ &= \sum_i x_i P(X = x_i|A)P(A) + \sum_i x_i P(X = x_i|\bar{A})P(\bar{A}) \\ &= P(A) \sum_i x_i P(X = x_i|A) + P(\bar{A}) \sum_i x_i P(X = x_i|\bar{A}) \\ &= P(A)E[X|A] + P(\bar{A})E[X|\bar{A}]. \end{aligned}$$

□

全期望公式对应于全概率公式的期望版本, 在很多应用中重要的性质. 该定理有一个关于随机变量的定理:

定理5.20. 对随机变量 X, Y , 有

$$E[X] = E[E(X|Y)] = \sum_{Y=y_j} P[Y = y_j] E[X|Y = y_j].$$

Proof. 利用全概率公式有

$$\begin{aligned} E[X] &= \sum_i x_i P(X = x_i) = \sum_i \sum_j x_i P(X = x_i, Y = y_j) \\ &= \sum_i \sum_j x_i P(X = x_i, Y = y_j) \\ &= \sum_j P(Y = y_j) \sum_i x_i \frac{P(X = x_i, Y = y_j)}{P(Y = y_j)} \\ &= \sum_j P(Y = y_j) \sum_i x_i P(X = x_i | Y = y_j) \\ &= \sum_j P(Y = y_j) E[X | Y = y_j]. \end{aligned}$$

□

通过全期望公式, 可以证明Markov不等式:

定理5.21 (Markov不等式). 设随机变量 $X \geq 0$, 对任意 $\epsilon > 0$, 有

$$P(X \geq \epsilon) \leq \frac{E(X)}{\epsilon}.$$

Proof. 利用全期望公式考虑随机事件 $X \geq \epsilon$, 有

$$E[X] = E[X | X \geq \epsilon] P(X \geq \epsilon) + E[X | X \leq \epsilon] P(X \leq \epsilon) \geq P(X \geq \epsilon) \epsilon$$

从而完成证明.

□

利用Markov不等式可以推导Chebyshev不等式:

定理5.22 (Chebyshev不等式). 设随机变量 X 的均值为 μ , 则

$$P(|X - \mu| > \epsilon) \leq \frac{\text{Var}(X)}{\epsilon^2}.$$

Proof. 根据Markov不等式有

$$P(|X - \mu| > \epsilon) = P((X - \mu)^2 \geq \epsilon^2) \leq \frac{E(X - \mu)^2}{\epsilon^2} = \frac{\text{Var}(X)}{\epsilon^2}.$$

□